高立恒

马来西亚籍 | +60 17-424 6282 | lihhanko526@gmail.com | GitHub | LinkedIn

工作经历

Kahap Inc | 软件开发工程师・兼职 2022.08–2026.08

- 从零开发并上线反馈平台，覆盖意见提交、讨论、后台审核和通知等核心流程。
- 长期维护 Laravel/Vue.js 线上系统，处理队列、定时任务、数据库迁移和 Linux 服务器问题。
- 在后端接入 GPT-SoVITS，并加入发音与文本检查，完善语音生成流程。

Pac Com Solution | 全栈开发实习生 2021.06–2022.01

- 负责 Laravel/Vue.js POS 系统的功能开发和线上问题修复。

研究经历

基于职场层级与情境脉络的隐含意图理解

硕士论文，国立清华大学 | NLP ・图学习・Role/Context KG ・Llama 3.1-8B

- 研究职场对话中会随上下文、说话者与听者角色变化的隐含意图，而不是只根据单句话判断。
- 将 LLM 提取的说话者/听者状态编码为 GCN/GAT 图表示，再通过 Role KG 与 Context KG 检索，为 Llama 3.1-8B 提供补充证据。
- 在 400 条 target-only 样本上，DualKG 的语义 F1 为 0.682，高于纯文本基线的 0.644，也高于 Prior KG、Role KG 和 Context KG。

项目经历

Small-Agent QLoRA

Python ・Qwen3.5-9B ・QLoRA / PEFT ・Transformers ・llama.cpp

- 开发可调用搜索、文件读取和 Python 的 Qwen Agent，并加入超时、重复调用拦截和运行追踪。
- 用失败案例整理纠错样本并做 QLoRA 微调，200 个固定任务的成功率从 34.5% 提升到 62.0%。
- GAIA100 准确率从 9% 提升到 18%；分析运行记录后，主要问题仍是过度搜索。

Hybrid Retrieval Evaluation

Python ・BM25 ・Qwen Embeddings ・RRF ・FastAPI

- 将 BM25 与 Qwen 向量检索通过 RRF 融合，并保留每条结果的排名来源，方便检查检索行为。
- 在 5,189 篇文档和 64 条查询上，Recall@10 从 0.734 提升到 0.763，MRR@20 从 0.679 提升到 0.742。

Semantic Text-to-SQL

Python ・FastAPI ・LangGraph ・SQLite ・Qwen3.5-9B ・pytest

- 开发 NL-to-SQL 流程，包含 Schema Grounding、确定性校验、有限次数修复和只读执行。
- FastAPI、CLI、Streamlit 与评测共用同一服务层，避免不同入口出现行为偏差。
- 在 100 条 BIRD DEV 查询上，正确率从 33% 提升到 39%，修复 6 条原本错误的查询，没有引入回退。

教育背景

国立清华大学（NTHU） | 信息系统与应用硕士・GPA 4.09/4.3 2026.06

中华大学 | 计算机科学与信息工程学士・GPA 3.9/4.0 2024.06

专业技能

AI / LLM	Agent 与工具调用；RAG / 混合检索；模型评测；PEFT / QLoRA；Transformers；LangGraph；llama.cpp
后端	Python；FastAPI；PHP；Laravel；REST API；SQL；MySQL；SQLite
Web / 工具	JavaScript；Vue.js；Linux；Git；pytest
语言	中文（母语）；英语（流利）；马来语（中级）