高立恒

KO LIH HAN | 软件工程师 | Applied AI / LLM Systems

马来西亚籍 | +60 17-424 6282 | lihhanko526@gmail.com | GitHub | LinkedIn

教育背景

国立清华大学（NTHU） | 信息系统与应用硕士 • GPA 4.09/4.3 2026.06
中华大学 | 计算机科学与信息工程学士 • GPA 3.9/4.0 2024.06

工作经历

Kahap Inc | 软件开发工程师 • 兼职 2022.08–2026.08

- 从零开发并上线反馈平台，整合意见提交、讨论、后台审核和通知流程。
- 负责 Laravel/Vue.js 线上系统维护，包括队列与定时任务、数据库/服务器迁移和 Linux 故障排查。
- 接入 GPT-SoVITS，并在后端加入发音与文本检查，服务语音生成流程。

Pac Com Solution | 全栈开发实习生 2021.06–2022.01

- 参与 Laravel/Vue.js POS 系统功能开发和缺陷修复，覆盖后端与部分前端工作。

项目经历

Small-Agent QLoRA | Python • Qwen3.5-9B • QLoRA / PEFT • Transformers • llama.cpp

- 用 Qwen3.5-9B 开发工具调用 Agent，支持搜索、文件读取和 Python 执行，并加入超时、重复调用拦截和运行追踪。
- 针对运行失败整理纠错样本并做 QLoRA 微调，200 个固定任务成功率从 **34.5%** 提升到 **62.0%**。
- 在 GAIA100 的 100 个任务上，准确率从 **9%** 提升到 **18%**；主要问题仍是过度搜索。

Semantic Text-to-SQL | Python • FastAPI • LangGraph • SQLite • Qwen3.5-9B • pytest

- 开发本地 NL-to-SQL 服务，包含 Schema Grounding、确定性校验、最多两次修复和只读执行。
- FastAPI、CLI、Streamlit 和评测共用同一服务层，避免应用路径与评测路径不一致。
- 在 100 条 BIRD DEV 查询上，正确率从 **33%** 提升到 **39%**，修复 6 条错误查询，未引入回退。

Hybrid Retrieval Evaluation | Python • BM25 • Qwen Embeddings • RRF • FastAPI

- 实现 BM25、Qwen 向量检索与 RRF 融合的本地混合检索，并保留结果的排名来源便于分析。
- 在 5,189 篇文档和 64 条 EnterpriseRAG-Bench 查询上，Recall@10 从 **0.734** 提升到 **0.763**，MRR@20 从 **0.679** 提升到 **0.742**。

研究经历

基於職場階層與情境脈絡之聽者隱含意圖解析 | 硕士论文 • 国立清华大学

- 整理并标注来自 7 个论坛的 20,455 条职场话语，标签包括说话者/听者状态、情绪和沟通目的。
- 设计 Role KG 与 Context KG 检索并结合 Llama 3.1-8B；在 400 条固定样本上，语义 F1 从 **0.644** 提升到 **0.682**。

专业技能

AI / LLM	Agent 与工具调用；RAG / 混合检索；模型评测；PEFT / QLoRA；Hugging Face Transformers；LangGraph；llama.cpp
后端	Python；FastAPI；PHP；Laravel；REST API；SQL；MySQL；SQLite
Web / 工具	JavaScript；Vue.js；Linux；Git；pytest
语言	中文（母语水平）；英语（流利）；马来语（中级）